PROJETO INTEGRADOR IV · FATEC

Quanto vale um jogador do Brasileirão?

Precificação baseada em desempenho e contexto para identificar jogadores sub e supervalorizados

Mariana Costa de Mello · Michelle de Salles Silva · Stephan Lucca Melo dos Santos

Leonardo de Lellis Rossi

O PROBLEMA

O valor de mercado reflete o que o jogador faz em campo?

Pergunta

Que fatores explicam o valor de mercado de um jogador do Brasileirão: perfil, desempenho ou o clube onde ele joga?

Objetivo

Construir um modelo que estime o valor esperado de cada jogador a partir de dados públicos.

Aplicação

Comparar valor real e previsto para apontar jogadores sub e supervalorizados.

OS DADOS

Duas temporadas do Brasileirão, dados públicos do Transfermarkt

475

linhas jogador-temporada na base de modelagem

358

jogadores diferentes, de 24 clubes

900

minutos mínimos jogados na temporada para entrar na base

2024 · temporada completa (380 jogos, 311 linhas), usada como treino

2025 · temporada incompleta (177 jogos, 164 linhas), usada como teste

METODOLOGIA

Oito notebooks, do dado bruto ao resultado

01	02	03	04	05	06	07	08
Coleta	Seleção	EDA	Variáveis	Baseline	Modelagem	Resíduos	Painel

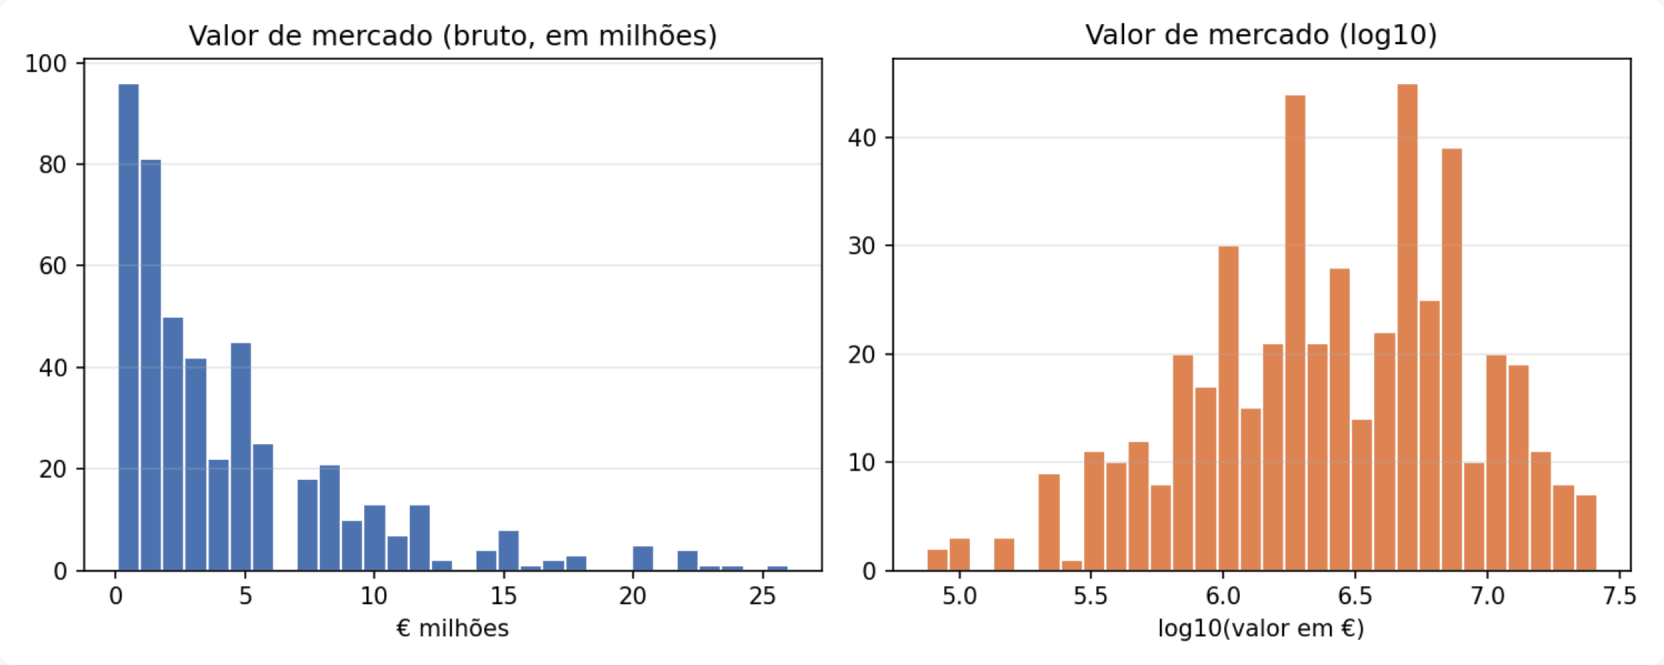
Preparação · baixar, filtrar o Brasileirão, explorar e criar as variáveis.

Modelagem · comparar com referências simples, ajustar o modelo e interpretar os erros.

Reprodutível: versão dos dados fixada, semente 42 em todo sorteio e bibliotecas fixadas no requirements.txt.

ANÁLISE EXPLORATÓRIA

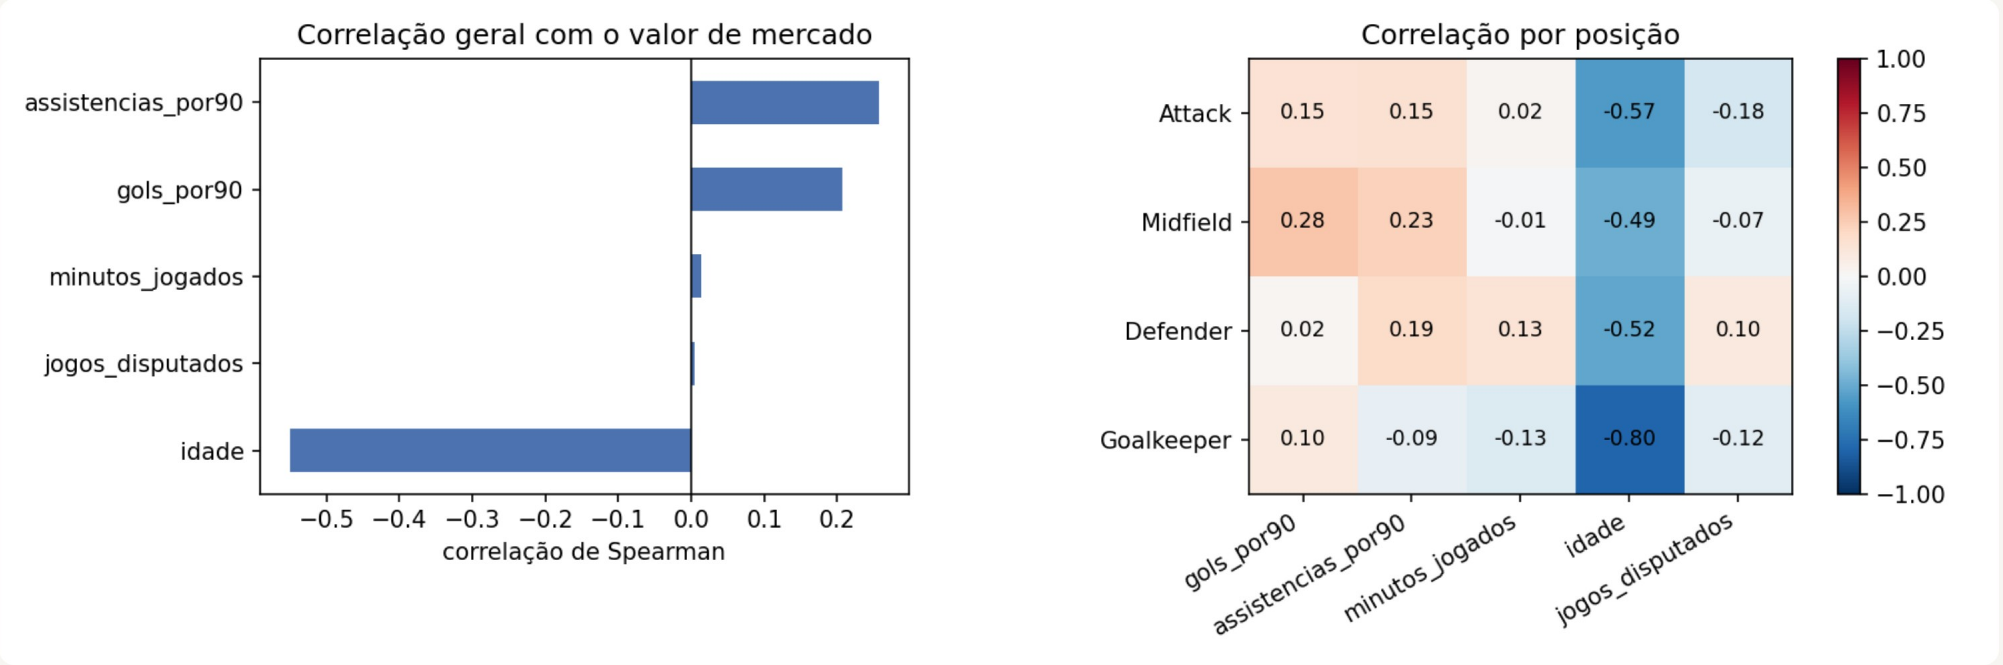
O valor de mercado é muito assimétrico



Por isso o alvo do modelo é o **log do valor de mercado**, que deixa a distribuição quase simétrica.

ANÁLISE EXPLORATÓRIA

A idade pesa mais que gols e assistências



Idade: **−0,55** (quanto mais novo, mais valioso). Gols e assistências por 90 min: relação positiva, mas fraca.

ENGENHARIA DE VARIÁVEIS

Quatro grupos de informação sobre cada jogador

Perfil

Idade e idade², posição, altura, pé preferencial, estrangeiro

Desempenho

Gols, assistências e cartões por 90 minutos, minutos e jogos

Contrato

Anos até o fim do contrato e indicador de contrato não informado

Contexto

Participação nos jogos do clube, subposição, força do clube e o próprio clube

COMO AVALIAMOS

Três validações, para não superestimar o modelo

K-Fold aleatório

Referência otimista: o mesmo jogador pode cair no treino e no teste.

GroupKFold por jogador

Validação principal: todas as linhas de um jogador ficam do mesmo lado.

Holdout temporal

Treina em 2024 e testa em 2025, simulando o uso real do modelo.

Métricas: **R^2** no log do valor e **MAE em euros** (erro médio absoluto).

BASELINE

Sem machine learning, a idade já explica parte do valor

Modelo	Nível	R^2 GroupKFold	R^2 holdout	MAE holdout
Mediana global	ingênuo	−0,02	−0,01	€ 4,08 mi
Mediana por posição	regra	0,01	0,06	€ 4,03 mi
Mediana por posição e idade	regra	0,31	0,44	€ 3,42 mi
Ridge só com perfil	modelo simples	0,43	0,50	€ 3,34 mi
Ridge completo	referência	0,53	0,62	€ 2,97 mi

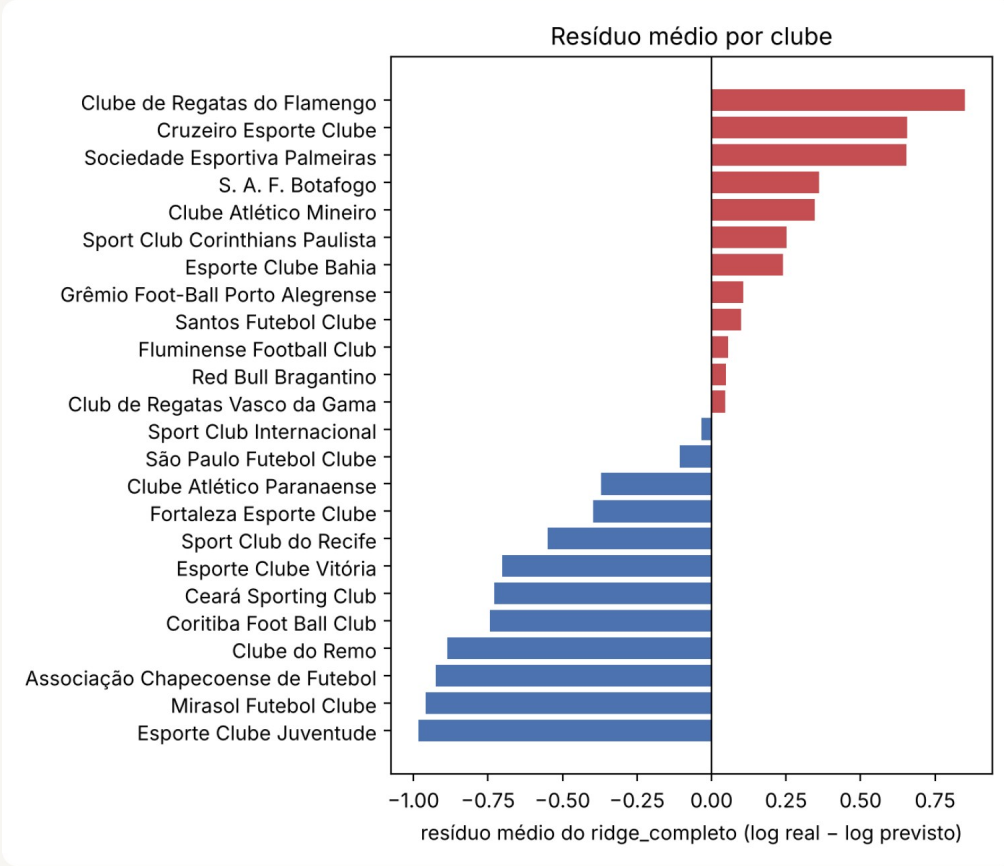
A referência a ser batida é o **Ridge completo**: R^2 de 0,53 e erro médio de € 2,97 milhões.

DIAGNÓSTICO

O baseline erra de forma diferente em cada clube

Subestima clubes grandes (Flamengo, Palmeiras, Cruzeiro) e superestima clubes menores (Juventude, Mirassol, Chapecoense).

Desvio do erro médio entre clubes: **0,56** em log. Falta ao modelo a informação do clube.



ABLAÇÃO

O clube é o bloco que mais acrescenta

Variáveis (acumuladas)	R^2 GroupKFold	R^2 holdout	MAE holdout
Ridge completo (baseline)	0,528	0,615	€ 2,97 mi
+ participação nos jogos	0,538	0,628	€ 2,93 mi
+ subposição	0,535	0,623	€ 2,93 mi
+ força do clube	0,588	0,675	€ 2,72 mi
+ clube (target encoding)	0,692	0,716	€ 2,38 mi

Participação e subposição somam pouco; força do clube e clube levam o R^2 de **0,53 para 0,69**.

ESCOLHA DO MODELO

Modelos de árvore não superam o Ridge

Algoritmo ajustado	R^2 validação 2024	R^2 holdout 2025	MAE holdout
Ridge (α = 0,1)	0,618	0,724	€ 2,37 mi
ElasticNet	0,618	0,723	€ 2,36 mi
Gradient Boosting	0,615	0,691	€ 2,49 mi
Random Forest	0,602	0,682	€ 2,59 mi
Hist. Gradient Boosting	0,573	0,670	€ 2,50 mi

ElasticNet empata com o Ridge (diferença de 0,000, menor que o desvio entre folds de 0,036). Pela simplicidade, fica o **Ridge**.

RESULTADO

O modelo final explica cerca de 70% da variação do valor

0,72

R^2 no holdout 2025 (baseline: 0,62)

€ 2,37 mi

erro médio no holdout (baseline: € 2,97 mi)

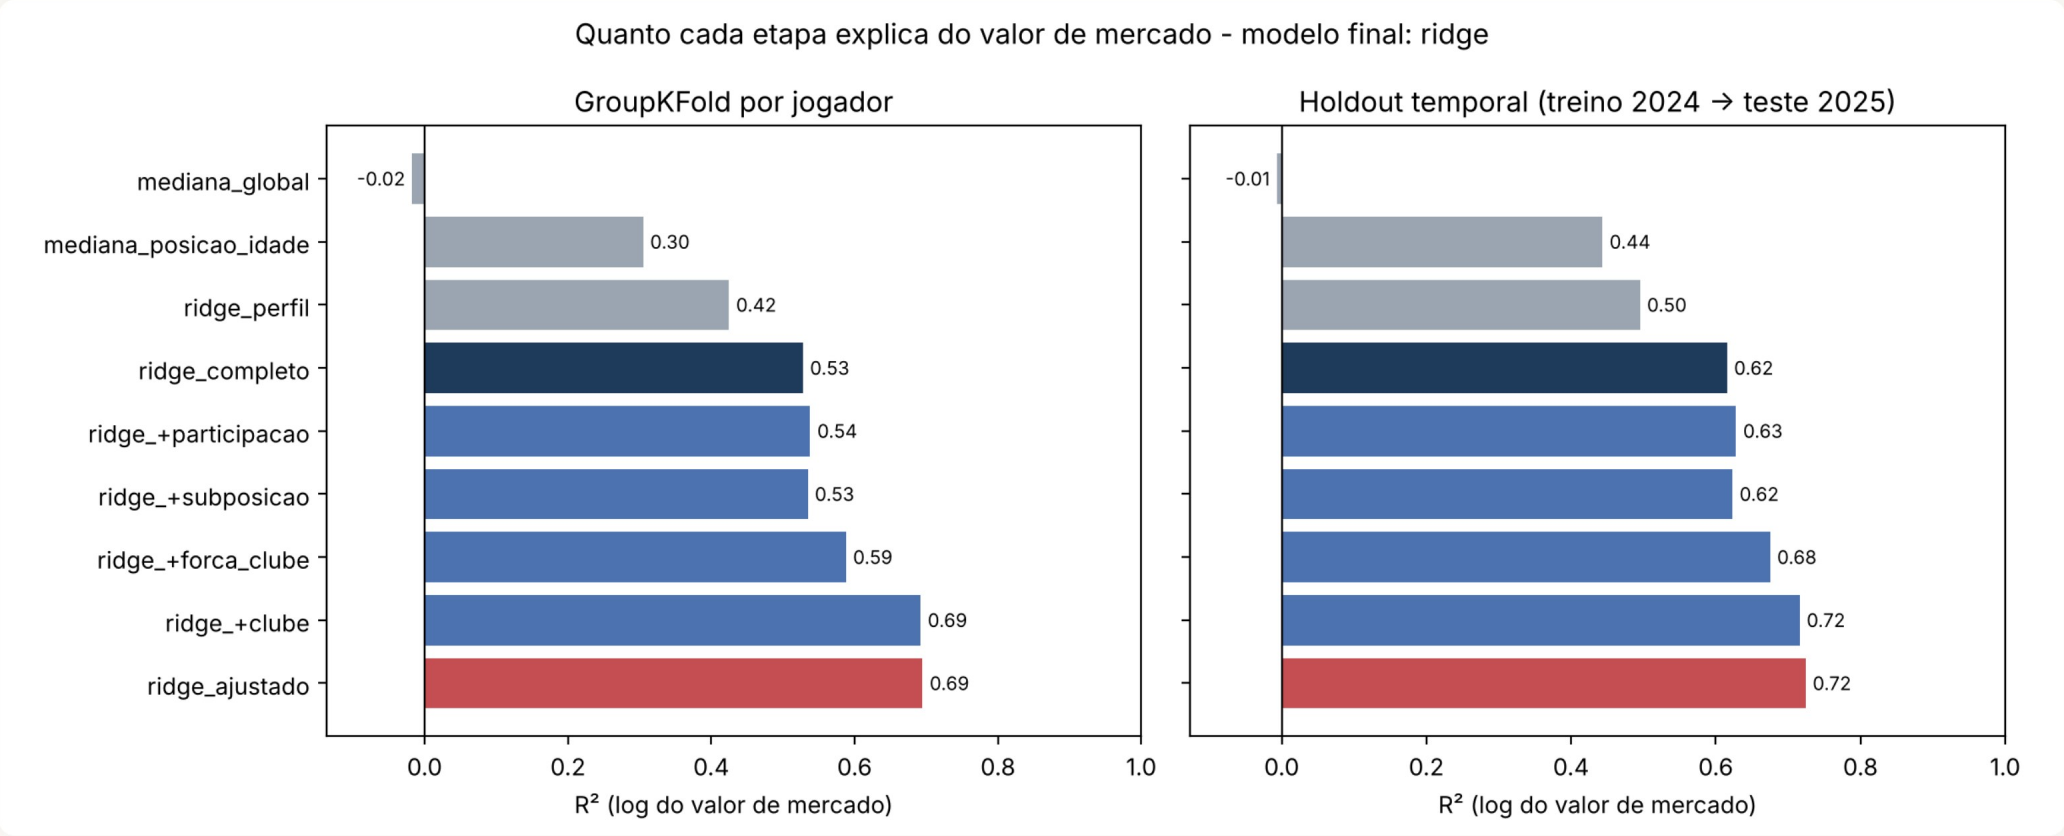
−42%

de erro em euros contra a mediana global

No GroupKFold, o R^2 vai de 0,53 para 0,70. Em log, o modelo erra em média por um fator de cerca de 1,8.

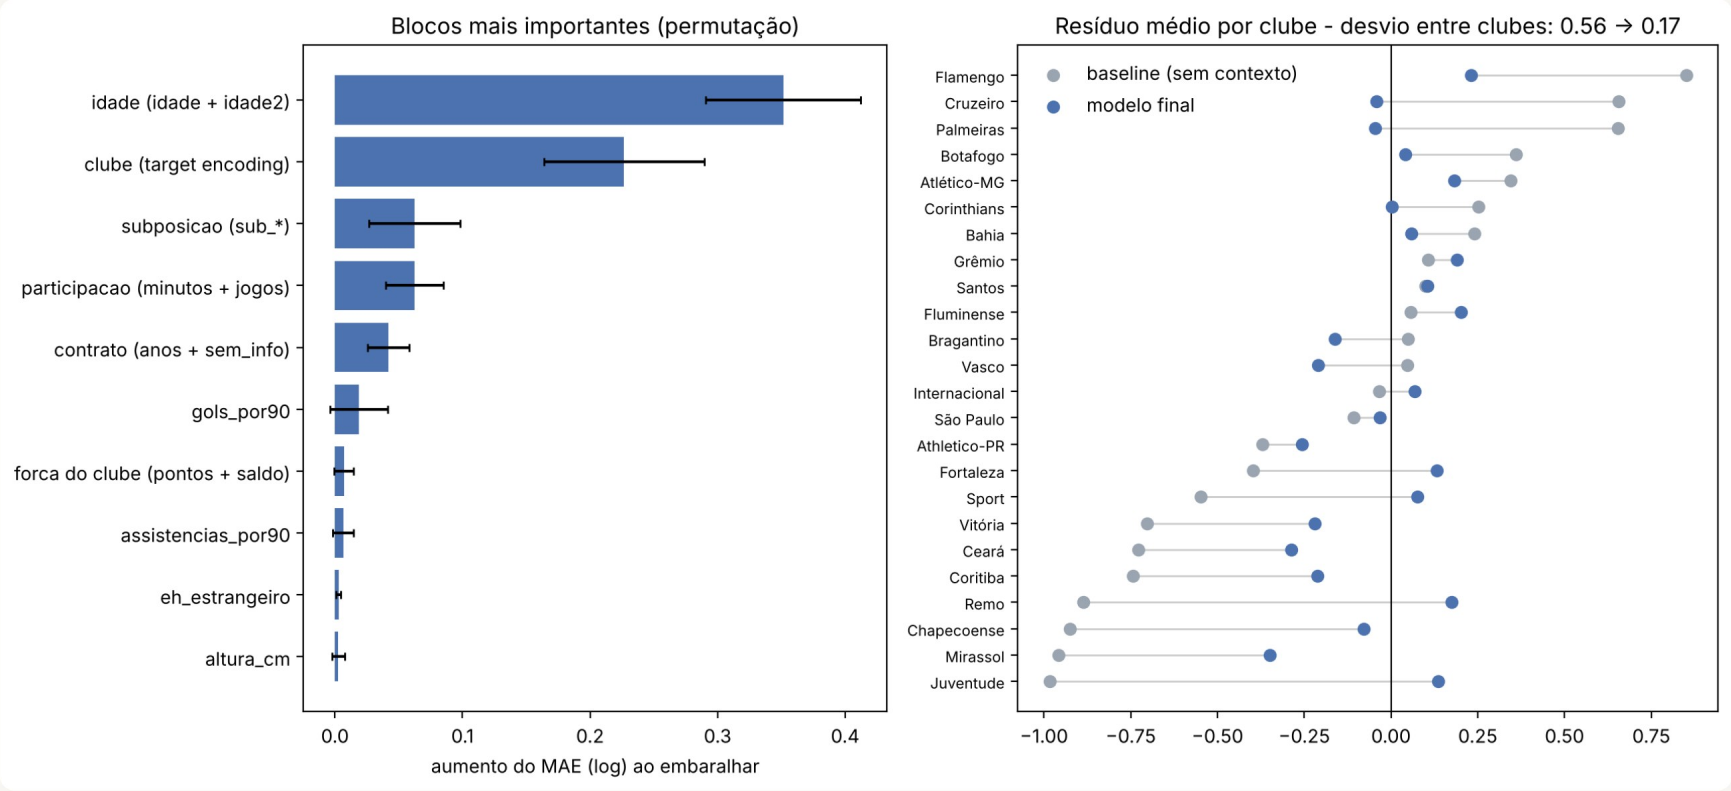
EVOLUÇÃO

Do piso ao modelo final, etapa por etapa



O QUE O MODELO USA

Idade e clube são o que mais pesa

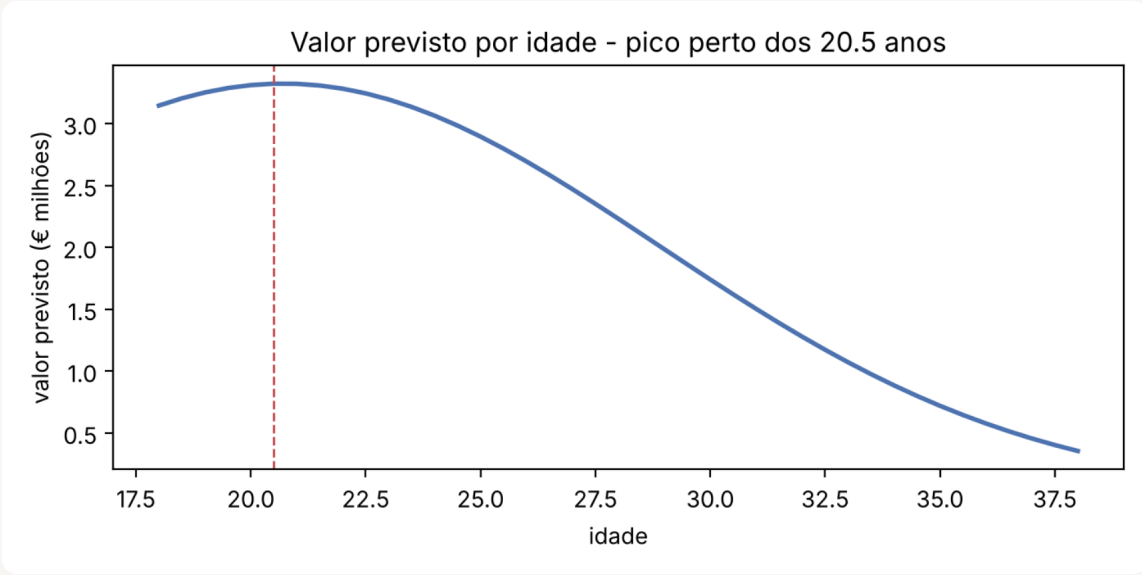


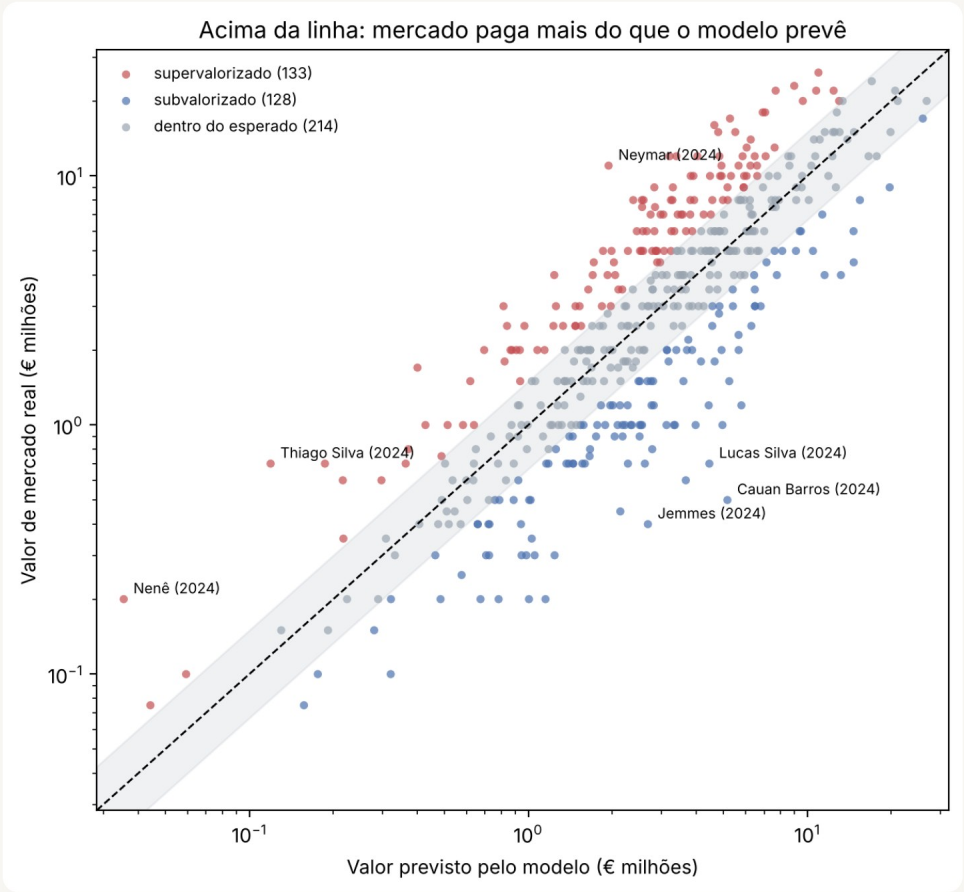
EFEITO DA IDADE

O valor cai a partir dos 20 anos

Para um jogador típico, o valor previsto vai de cerca de **€ 3,3 milhões aos 20** para **€ 0,7 milhão aos 35**.

Contrato mais longo e mais participação em minutos aumentam o valor; zagueiros e laterais valem menos.





SUB E SUPERVALORIZADOS

Comparando valor real e valor previsto

Limiar: diferença de pelo menos 50% entre real e previsto.

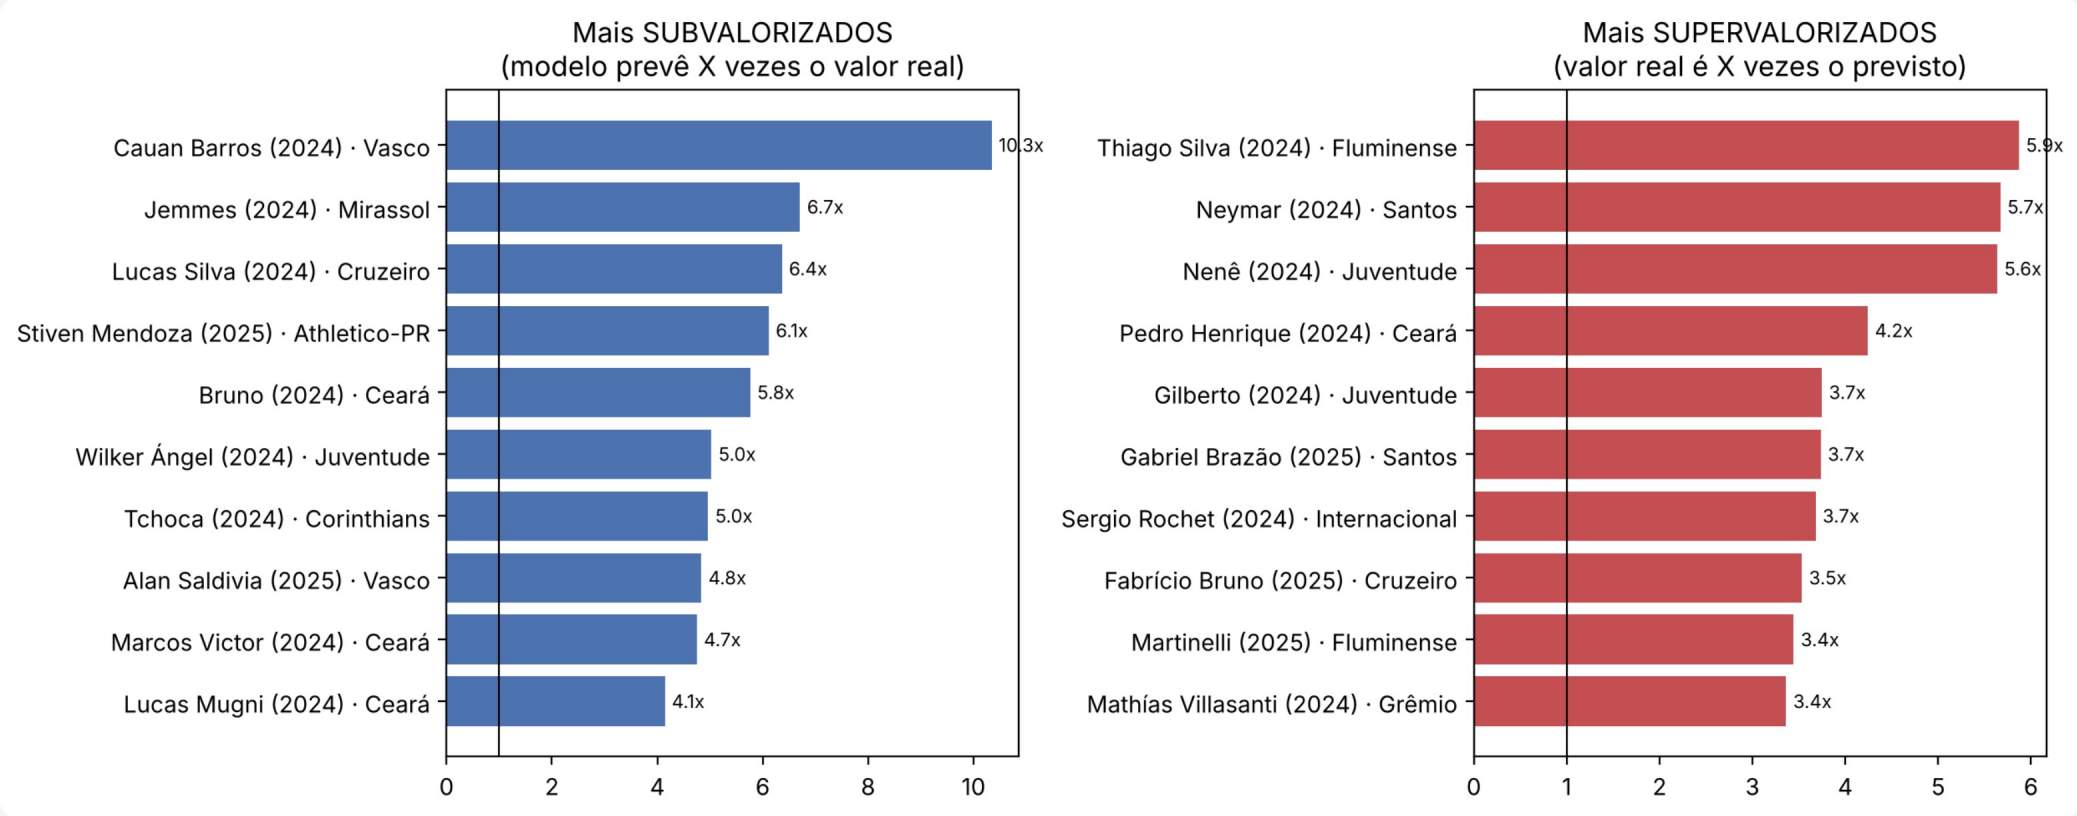
214 dentro do esperado

133 supervalorizados (mercado paga mais)

128 subvalorizados (mercado paga menos)

CASOS EXTREMOS

Veteranos lideram os supervalorizados



O RESÍDUO SE REPETE?

Existe um efeito do próprio jogador

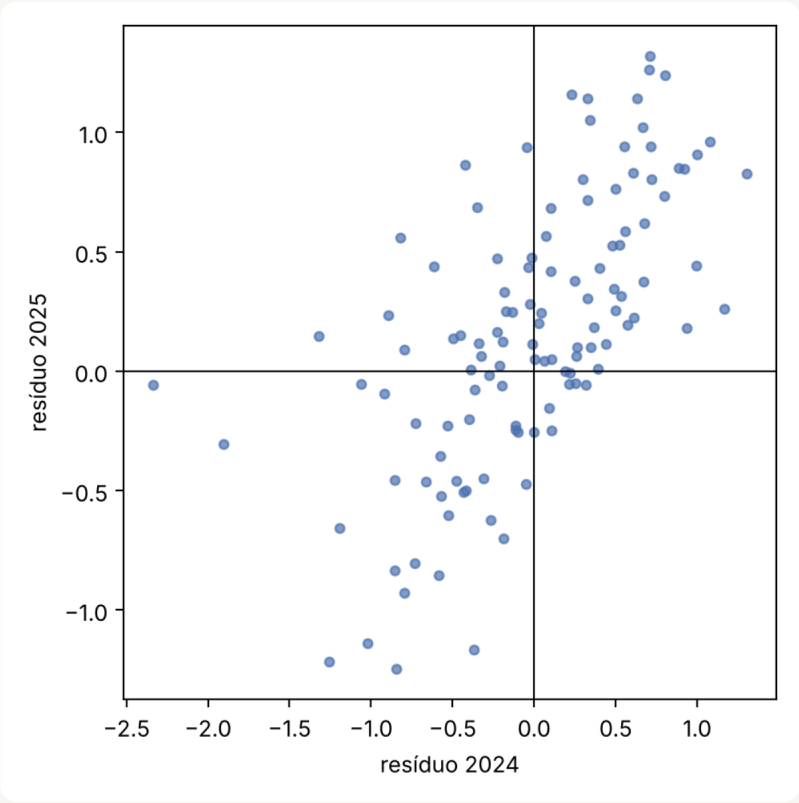
0,64

correlação do resíduo entre 2024 e 2025

74%

dos jogadores mantêm o mesmo sinal

Quem foi supervalorizado em 2024 tende a continuar em 2025: o erro não é ruído, é informação que falta na base.



CONCLUSÕES

O mercado paga pelo perfil e pelo clube

O que aprendemos

Idade e clube explicam a maior parte do valor; o desempenho em campo acrescenta pouco. A relação é praticamente linear.

Limitações

Só duas temporadas, 2025 incompleta e o corte de 900 minutos, que deixa 2025 com viés (+0,06). Faltam reputação e seleção.

Próximos passos

Mais temporadas, dados de seleção e redes sociais, e acompanhar se os subvalorizados se valorizam depois.

Obrigado!

Perguntas?

Mariana Costa de Mello · Michelle de Salles Silva · Stephan Lucca Melo dos Santos · Leonardo de Lellis Rossi